ระบบรวบรวมราคาขายส่งผัก-ผลไม้จาก 3 ตลาดกลาง

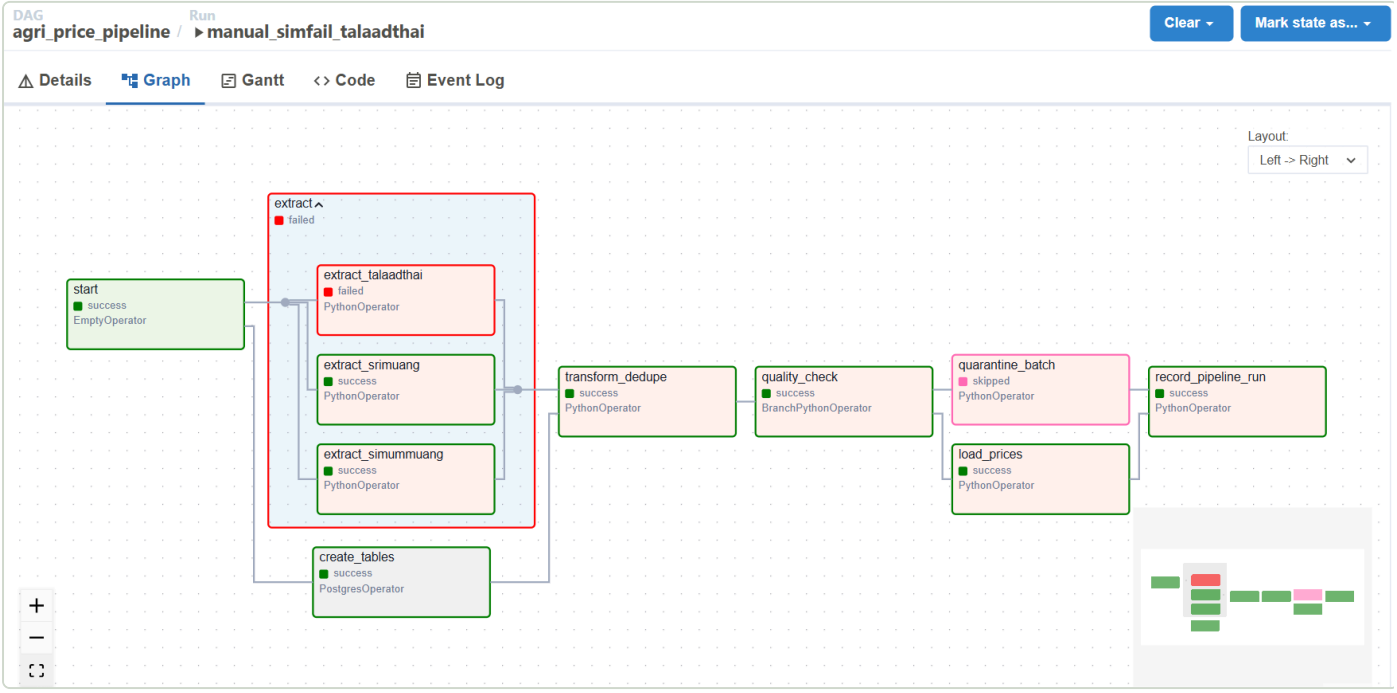
02739452 แพลตฟอร์มข้อมูลขนาดใหญ่และการวิเคราะห์ · สอบปลายภาค ภาคต้น 2569

อริยชัย สุวรรณเกิด · รหัสนิสิต 6621650671 · เลขที่ 9

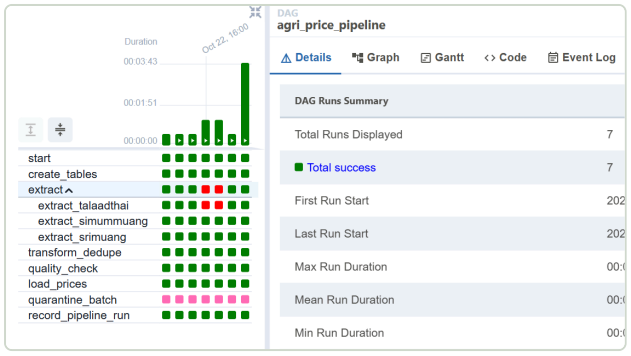
GitHub: https://github.com/arinchaisuwannakerd/02739452-9-6621650671 · หมวด: ราคาสินค้าเกษตร · ขอบเขต: ราคาขายส่งผักและผลไม้รายวัน 3 ตลาดกลาง (ปทุมธานี 2 แห่ง และราชบุรี)

1. ภาพรวมงานแต่ละส่วน (ทำได้ครบระดับ 1 + 2 + 3 + โบนัส)

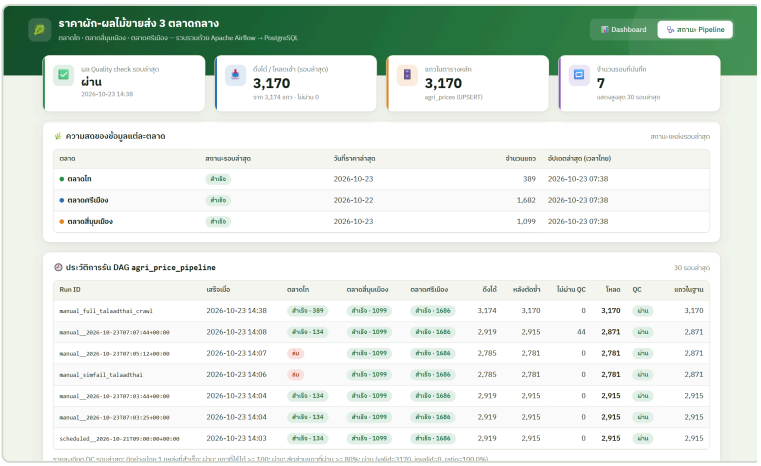
ส่วน	สิ่งที่ทำ
แหล่งข้อมูล	① **ตลาดไท**: **web scraping** อ่าน `products-sitemap.xml` แล้วดึงหน้า HTML `/products/<slug>` **ทุกหน้า (~1,500 หน้า)** ด้วย requests + BeautifulSoup (พร้อมกันไม่เกิน 4 หน้า) และแกะ `<script id="__NEXT_DATA__">` (robots.txt ห้ามเฉพาะ *.json/*.js และไม่ใช้ Selenium) ② **ตลาดสี่มุมเมือง**: JSON API ที่หน้า /pricing เรียกใช้ แบ่งหน้า 100 รายการ/หน้า ราคาแยกขนาด เล็ก/กลาง/ใหญ่ ③ **ตลาดศรีเมือง ราชบุรี**: JSON API ราคารายวัน backfill ย้อนหลัง 7 วัน ไม่เก็บข้อมูลส่วนบุคคล (ไม่มีชื่อหรือเบอร์โทรผู้ค้า) และหน่วง 0.5 วินาที/request
ระดับ 1	DAG `agri_price_pipeline` : extract → `transform_dedupe` → `load_prices` ลง PostgreSQL (`postgres_target`) แล้วแสดงตารางและกราฟบนเว็บ Flask ที่อ่าน PostgreSQL โดยตรง
ระดับ 2	3 แหล่งรันขนานใน **TaskGroup** `extract` แปลงเป็น schema เดียว (source, market, product_name, product_key, category, unit, grade, price_min/max/avg, price_date) และ **UPSERT** ด้วย `ON CONFLICT (source, product_id, grade, price_date)` ทดสอบรันซ้ำแล้วจำนวนแถวไม่เพิ่ม เว็บมี **KPI 5 ตัว** และ**ตัวกรอง** 5 แบบ (ตลาด/หมวด/วันที่/ค้นหา/สินค้า)
ระดับ 3	• **แหล่งล่มแล้วไปต่อได้:** `transform_dedupe` ใช้ `trigger_rule=all_done` ทดสอบด้วย config `{"simulate_fail": ["talaadthai"]}` แล้ว DAG ยังรวม 2 ตลาดที่เหลือจนสำเร็จ (ภาพด้านล่าง) • **ตัดรายการซ้ำข้ามแหล่ง:** แปลงชื่อเป็น `product_key` (ตัดวงเล็บ เบอร์/ขนาด ตัวเลข) แล้วยุบสินค้าเดียวกันจากหลายตลาดเป็น 1 แถวในตาราง `product_master` จับคู่ได้ **175 สินค้า**ที่มีขายมากกว่า 1 ตลาด • **ตรวจคุณภาพแล้วแตกเส้นทาง:** `quality_check` (BranchPythonOperator) ตรวจราคา > 0, ราคาไม่เกิน 100,000, ราคาไม่ค้างเกิน 30 วัน, แถวใช้ได้ ≥ 100 และสัดส่วนผ่าน ≥ 80% ถ้าผ่าน → `load_prices` ถ้าไม่ผ่าน → `quarantine_batch` (เก็บลง `agri_prices_rejected`)
โบนัส	หน้า **/status** แสดงสถานะ pipeline รายรอบ (สถานะแต่ละแหล่ง, จำนวนแถว, ผล QC และความสดของข้อมูล) จากตาราง `pipeline_runs` ที่ task `record_pipeline_run` บันทึก
ผลลัพธ์	ข้อมูลรวม **3,170 แถว** (ตลาดไท 389 · สี่มุมเมือง 1,099 · ศรีเมือง 1,682), สินค้า 978 รายการ, 28 วันที่ราคา, บันทึก 7 รอบการรัน (ข้อกำหนดขั้นต่ำ 100 รายการ)



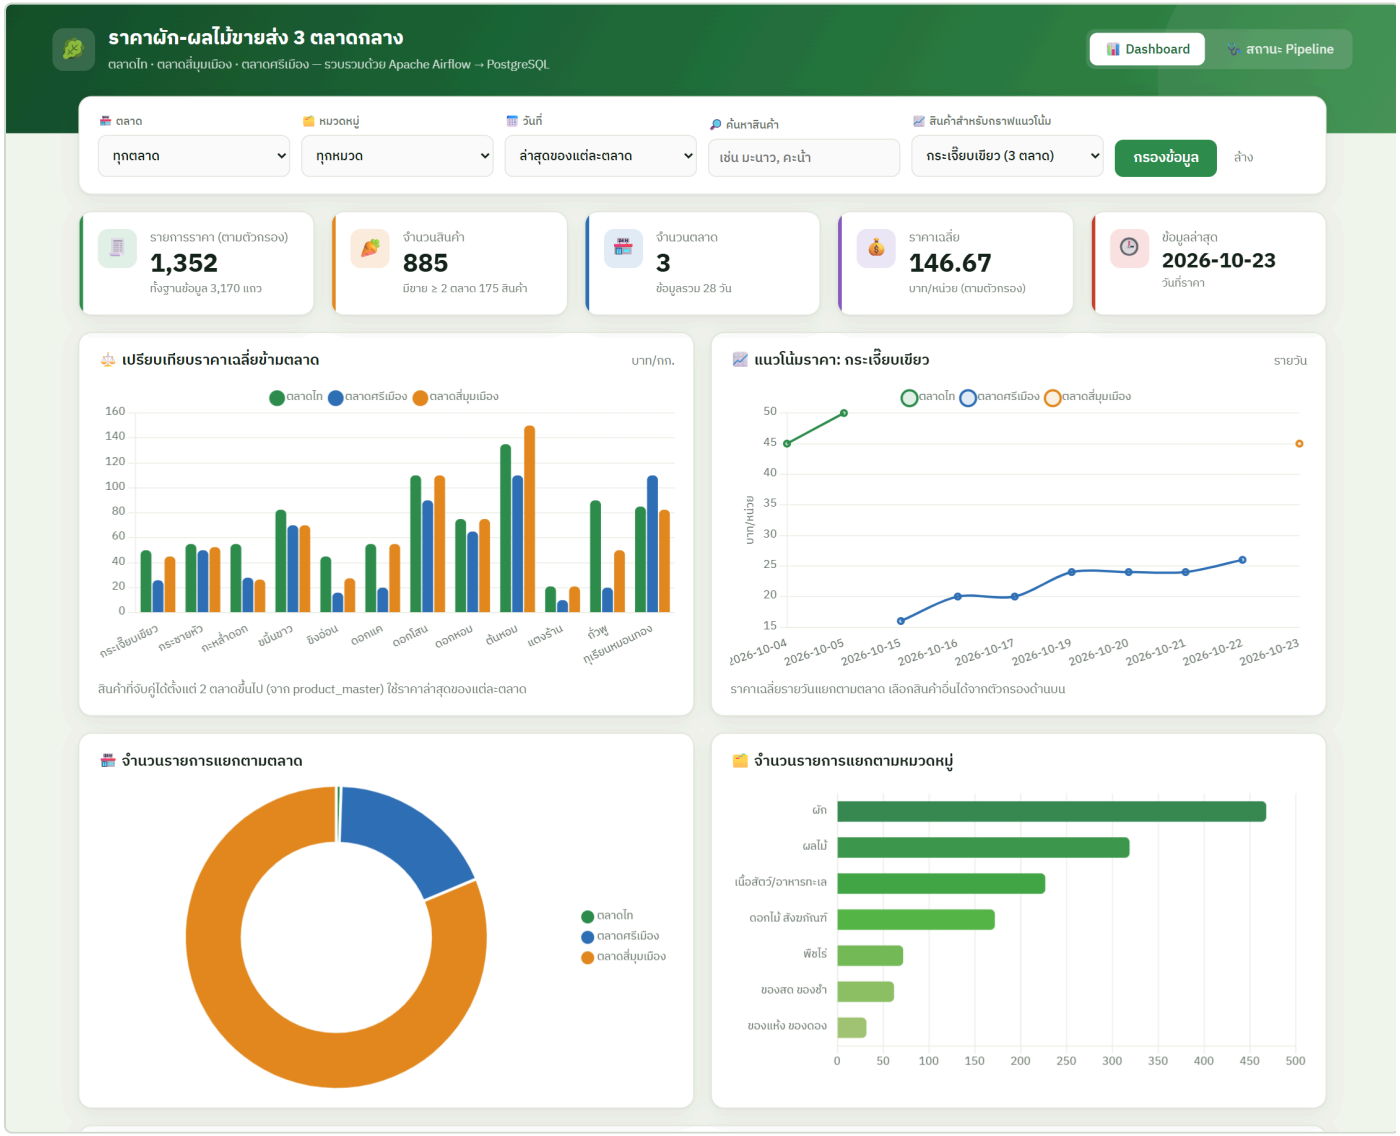
ภาพที่ 1 Graph view รอบ `manual_simfail_talaadthai` : TaskGroup `extract` รัน 3 ตลาดขนาน ตลาดไทถูกจำลองให้ล่ม (แดง) แต่ transform/QC/load ยังทำงานต่อ ส่วน quarantine_batch ถูก skip เพราะ QC ผ่าน



ภาพที่ 2 Grid view: ทุกรอบสำเร็จ แถบแดงคือ extract_talaadthai ในรอบทดสอบแหล่งล่ม และ quarantine_batch เป็น skipped (ชมพู) ทุกรอบเพราะ QC ผ่าน



ภาพที่ 3 หน้าสถานะ pipeline (/status) ของโบนัส



ภาพที่ 4 เว็บ dashboard (http://localhost:8050): KPI, ตัวกรอง, กราฟเปรียบเทียบราคาสินค้าเดียวกันข้ามตลาด, แนวโน้มราคา และกราฟจำนวนรายการ (ส่วนล่างของหน้าเป็นตารางข้อมูล)

2. ปัญหาที่พบและวิธีแก้

ปัญหา	อาการ	วิธีหาสาเหตุ	วิธีแก้
1. SSL ของ API ตลาดศรีเมือง	`requests` error `CERTIFICATE_VERIFY_FAILED: unable to get local issuer certificate` แต่เปิดในเบราว์เซอร์และ curl บน Windows ได้	ใช้ `openssl s_client -showcerts` แล้วพบว่าเซิร์ฟเวอร์ส่งมาแค่ใบ leaf ขาด intermediate "RapidSSL TLS RSA CA G1" (เบราว์เซอร์ดึงเองผ่าน AIA แต่ Python ไม่ดึง)	ดาวน์โหลด intermediate จาก URL AIA ของ DigiCert เก็บไว้ที่ `dags/certs/` แล้วรวมกับ certifi เป็น CA bundle ส่งให้ `verify=` ยังตรวจ SSL ตามปกติ **ไม่ใช้ verify=False**
2. หน้าราคาสี่มุมเมืองไม่มีข้อมูลใน HTML	ดึงหน้า /pricing แล้วได้ "แสดงสินค้า 0 จาก 0 รายการ" เพราะหน้าเว็บเป็น Next.js ที่โหลดราคาด้วย JavaScript ภายหลัง	ดาวน์โหลด JS bundle ของหน้าแล้วค้นคำว่า `fetch(` และ `/app/products` พบ endpoint `api.simummuangmarket.com/api/app/products` ทดลองเรียกแล้ว limit=200 ได้ error "limit must not be greater than 100"	เรียก API ที่หน้าเว็บใช้โดยตรงแบบแบ่งหน้า (limit=100 วนตาม totalPages) ไม่ต้องใช้ Selenium ส่วนตลาดไทใช้วิธีแกะ `__NEXT_DATA__` จาก HTML
3. Docker Desktop เปิดไม่ขึ้น	`docker` ต่อ engine ไม่ได้ (`dockerDesktopLinuxEngine` not found) และ WSL distro `docker-desktop` อยู่ในสถานะ Stopped	อ่าน `%LOCALAPPDATA%\Docker\log\host\com.docker.backend.exe.log` พบ "backend crashed … remove … \run\dockerInference: The file cannot be accessed by the system" คือไฟล์ unix socket เก่าค้างและลบไม่ได้ (เจอซ้ำที่ docker-secrets-engine)	ปิด Docker แล้ว**เปลี่ยนชื่อโฟลเดอร์**ที่มี socket ค้าง (`run`, `docker-secrets-engine`) ให้ Docker สร้างโฟลเดอร์ใหม่ (ลบไฟล์ socket ตรงๆ ไม่ได้) จากนั้นเปิดใหม่แล้ว engine ขึ้นปกติ
4. ราคาตลาดไทบางรายการค้าง	กราฟแนวโน้มมีวันที่ปี 2023 และ KPI "จำนวนวัน" สูงผิดปกติ	query `min(price_date)` แยกตามแหล่ง พบว่าสินค้าบางตัวของตลาดไทมีราคา "วันก่อนหน้า" เป็นข้อมูลเก่าหลายปี	เพิ่มกฎใน quality check ว่าราคาเก่ากว่า 30 วันถือว่าค้าง และส่งไปตาราง rejected แทนตารางหลัก

3. การวางแผนและจัดลำดับงาน

การแบ่งเวลา (13:00–16:00)

ช่วงเวลา	งาน (เหตุผลของลำดับ)
13:00–13:30	อ่านโจทย์และ workshop (docker-compose/DAG ตัวอย่าง) เลือกหัวข้อ และสำรวจแหล่งข้อมูลพร้อมตรวจ robots.txt (ตัด kasetprice.com เพราะ robots ห้ามบอท AI) *(แหล่งข้อมูลคือความเสี่ยงสูงสุด ต้องยืนยันว่าดึงได้จริงก่อนเขียนโค้ด)*
13:30–13:50	เขียน `sources.py` (extract + normalize) แล้วทดสอบนอก Airflow จนได้ข้อมูลครบ 3 แหล่ง *(แยกโค้ดดึงข้อมูลออกจาก DAG ทำให้ทดสอบได้เร็วโดยไม่ต้องรอ Docker)*
13:50–14:00	เขียน DAG, docker-compose.yml, เว็บ Flask และ README แล้ว commit แรกระหว่างรอ Docker *(commit เร็วเพื่อกันความเสี่ยงเรื่องเวลา (นับเฉพาะ commit ก่อน 16:00))*
14:00–14:15	แก้ Docker, build image, รัน DAG และทดสอบ UPSERT (รันซ้ำ) และแหล่งล่ม (simulate_fail) *(ทดสอบตามเกณฑ์ทีละระดับ 1 → 2 → 3)*
14:15–15:15	ขยายการ scrape ตลาดไทจากหน้าเดียวเป็นทุกหน้าสินค้า (~1,500 หน้า), ตกแต่ง dashboard, ถ่ายภาพ Graph/Grid/เว็บ และทำ PDF สรุป *(ทำหลังระบบทำงานครบแล้วเท่านั้น)*
15:15–16:00	เผื่อเวลา: ตรวจ repo public, ทดลองรันตาม README และส่งงาน *(อาจารย์จะรันจาก repo จริง)*

งานที่ตัดออกและเหตุผล

- **Dynamic Task Mapping:** เลือกทำหน้าสถานะ pipeline แทน เพราะโบนัสให้เพียงข้อเดียว (+5) และ 3 แหล่งมี extractor ต่างกัน จึงเขียนเป็น task แยกใน TaskGroup ได้ชัดเจนกว่า
- **เก็บราคาสินค้าตลาดไทที่ไม่อัปเดตเกิน 30 วัน:** ดึงครบทุกหน้า (~1,500 หน้า) แต่ราว 2,000 แถวเป็นราคาค้างตั้งแต่ปี 2023–2025 จึงไม่นำเข้า เพื่อไม่ให้การเปรียบเทียบราคาข้ามตลาดผิดเพี้ยน
- **แปลงหน่วยราคาให้เป็นต่อกิโลกรัมทุกหน่วย** (กระสอบ/กำ/ลูก): หน่วยไม่มีน้ำหนักมาตรฐาน จึงเปรียบเทียบข้ามตลาดเฉพาะหน่วย "กิโลกรัม"
- **Backfill ย้อนหลังยาว / การแจ้งเตือนทางอีเมล หรือ LINE / ระบบ login ของ dashboard:** ไม่อยู่ในเกณฑ์คะแนน และใช้เวลาเกินกรอบ 3 ชั่วโมง